判别模型与生成模型

王君銘

厦门大学

1 机器学习

生成模型和判別模型是机器学习中的术语。机器学习是指通过计算机使用算法,利用已有的数据,得出某种模型,并用该模型进行预测的一种方法。根据训练数据是否有标签,即是否可以被区分,机器学习可以分为有监督学习和无监督学习。假设训练数据为 $Y\{y_1,y_2,y_3,....\}$,有监督学习已知 Y中数据的分类,而无监督学习则不知道 Y中数据的分类。比如 Y 是硬币和游戏币的集合,如果知道 y_i 是硬币或游戏币,则此为有监督学习,如果不知道 y_i 是硬币还是游戏币,则为无监督学习。在监督学习中通常要预测两个变量之间的关系,根据已知的 x,判断 y,比如根据币的重量判断究竟是硬币还是游戏币。但是目标 y,往往并不仅仅由一个外生变量 x 决定,还有其他的因素可能会影响 y,。那么如何在只观测到 x 的情况下预测 y 呢?一般来说通常有三种方法能够预测 y。

- 1. 先估计出 p(y|x) 的分布, 然后再根据目标的损失方程来估计 y。
- 2. 找到一个 f(x) 使得 y = f(x) + e,即直接用 x 的值来估计 y 的值,将其他变量对 y 的影响放入偏差项 e 中。
- 3. 先找到 p(x,y),即 x 与 y 的联合分布概率函数,再根据 x 分布确定条件分布 p(y|x),因为 $p(x|y)=\frac{p(x,y)}{p(x)}$ 知道 p(y|x) 后就可以估计 y 了。

可以看到方法 1 和 2 的模型,都是在给定 x 的情况下预测 y,而模型 3 则根据 x,y 之间的分布来预测 y。两者之间存在明显区别。在以上三种预测 y,的模型中,前两种称为判别模型,最后一种称为生成模型。

2 判别模型与生成模型

2.1 定义

判別模型是指根据数据 x 直接估计决策函数 f(x) 或者条件概率分布 p(y|x) 并由此预测 y 的模型。判別模型强调的是对于给定的输入值 x,根据模型可以预测出相应的输出值 y,即可以判定相应的 y 所属的类别,因此被称为判别模型。经典的判别模型有感知机、决策树、逻辑回归、线性回归等。生成模型是由数据集 (x,y) 估计出联合概率密度分布 p(x,y),然后求出条件概率 p(y|x),并预测 y 的模型。生成模型展现了给定输入值 x 而产生输出值 y 之间的生成关系,生成模型不仅可以用给定的 x 来预测 y,还可以根据模型估计的 $\hat{p}(x,y)$ 生成新的 (x,y) 的数据集,因此该模型被称为生成模型。经典的生成模型有朴素贝叶斯、隐马尔可夫、高斯混合模型。 \bar{p}

2.2 特点

数据上,判别模型不能反映数据本身的特点,它寻找不同类别之间的最优分类面,反映的是异类数据之间的差异。生成模型可以从统计的角度反映数据的分布情况,能够反映同类数据本身的相似度,但不关心数据的分类边界。

样本量上,生成模型需要的样本量较大,需要从大量的样本数据中寻找规律,才能较好地估计概率密度函数。而判别模型不需要这么多的样本量,因此在实践中,用判别模型能够简化学习问题,进行预测的效果较好。

联系上,生成模型的联合概率密度分布 p(x,y) 还原出判别模型的条件概率分布 p(y|x),而判别模型不能反推出生成模型。

2.3 应用

判别模型主要应用于预测与分类,而不需要提供实际生成这些数据点的模型。比如根据人脚的大小而去预测人的身高或根据币的重量预测是属于游戏币还是硬币。

生成模型模拟个体之间的分布,因此生成模型不仅能用于预测与分类还能应用于其他方面,比如生成人工合成数据,这个生成人工合成数据的过程叫做模拟,可以用模拟进行反事实推断。p(x,y)与p(y)生成p(y|x)。科学模型就是一种很重要的生成模型,科学模型描述了数据之间因果机制。我

们不仅能用 x 来推测 y,还能用 y 来反推 x。比如牛顿第二定律 F=ma,我们可以根据作用在物体上的力和物体的质量判断物体的加速度。

参考文献

- [1] 机器学习基本概念
- [2] 生成模型 VS 判别模型 (含义、区别、对应经典算法)
- [3] 机器学习与深度学习里生成模型和判别模型的理解
- [4] Foundations of Statistical Learning, mao jiaming