

# 神经网络及其应用

王君铭 吴艳辉


厦门大学

## 1 引言

神经网络 (neural network) 是重要的机器学习技术, 也是深度学习 (deep learning) 的重要基础。神经网络因为其结构形似人脑中的神经元而命名。通常线性模型是我们常用的模型, 但是有时候我们在对样本进行分类时, 很难找用一条线性分类边界对样本进行分类。因此神经网络在分类问题中的效果很好, 特别当神经网络在三层及以上时, 能够很好地进行非线性可分。

## 2 神经网络

神经网络模型是一个包含输入输出与计算功能的模型, 由输入层、隐藏层、输出层构成。当只有输入层和输出层两层时被称为感知器 (perceptron), 当层数大于三时即可被称为深度学习 (deep learning)。输入层的每个神经元代表了一个特征, 输出层个数代表了分类标签的个数。隐藏层层数和隐藏神经元是由人工设定的。在层与层之间存在箭头连接, 每个连接上都有权重, 每个隐藏神经元/输出神经元的值, 都是由上一层神经元经过加权求和非线性变换而得到的, 其中的非线性变换函数可以是: sigmoid、tanh、relu 等函数。具体如下所示



神经网络

神经网络的训练算法就是优化神经网络的目标函数，从而进行参数学习，让目标权重值调整到最佳使得整个网络的预测效果最好。假设输出层只有一个神经元，而网络有  $k$  层，则其目标函数为

$$J(\theta) = -\frac{1}{m} \left[ \sum_{i=1}^m y^{(i)} \log \left( h_{\theta} \left( a^{(K-1)} \right) \right) + \left( 1 - y^{(i)} \right) \log \left( 1 - h_{\theta} \left( a^{(K-1)} \right) \right) \right] + \frac{\lambda}{2m} \sum_{k=1}^{N_k} \sum_{i=1}^{N_k} \sum_{j=1}^{N_{k+1}} \left( \theta_{ji}^{(k)} \right)^2$$

### 3 神经网络优化算法

由于神经网络的最后一层输出和每层的神经元都有关系，因此神经网络的每一层与下一层之间都存在一个参数举着，我们需要通过优化算法求出每一层的参数矩阵，对于一个  $K$  层神经网络，一共需要求解  $K-1$  个参数矩阵，因此无法直接对目标函数进行梯度计算来求解参数矩阵。

对于神经网络的优化主要需要两步：前向传播（forward propapagation）和反向传播（back propagation）。前向传播就是从输入层到输出层计算每一层每一个神经元的值。反向传播就是根据前向传播计算出来的值来计算每一层参数的梯度，并从后往前进行参数的更新。

在训练神经网络时，最好去标准化所有的输入值，使其均值为 0，标准差为 1. 同时为了避免过度拟合，一般情况下，需要对优化加一些惩罚项。加了惩罚项的后的损失模型如下：

$$E_{\text{aug}}(w) = E_{\text{in}}(w) + \lambda \|w\|^2$$

也可以通过限制隐藏层的节点数量来控制模型的复杂程度。在实践中，惩罚项是更加常用的方法。

### 4 神经网络的代码实现

本文给出以下实例，说明如何用神经网络模型解决多元离散选择问题，即用神经网络模型分析决策者  $i$  在面对  $(J+1)$  项可供选择方案时，如何进行选择的问题。


首先用 `make_moons` 函数，自动生成可以操作的数据集。

```
In [1]: import matplotlib.pyplot as plt
import numpy as np
import sklearn
import sklearn.datasets
import sklearn.linear_model
import matplotlib

In [2]: %matplotlib inline
matplotlib.rcParams['figure.figsize'] = (10.0, 8.0)
```

```
np.random.seed(3)
X, y = sklearn.datasets.make_moons(400, noise=0.20)
plt.scatter(X[:,0], X[:,1], s=40, c=y, cmap=plt.cm.Spectral)
```

Out [2]: <matplotlib.collections.PathCollection at 0x1a194e7400>



生成的数据集中有两种类型的数据，分别用红点和蓝点表示。我们将蓝点视为 A 类群体，将红点视为 B 类群体，并且将 x 轴和 y 轴视为区分 A、B 类群体的方式。

我们的目的是形成一个学习分类器，让它在 x、y 坐标系下预测正确的类别（A 类或者 B 类）。从图中可以发现这些数据不能被线性分割，我们无法画出一条直线将这两种类型的数据分开，这意味着线性分类器（比如 Logistic 回归）将无法很好的拟合这些数据。

所以，我们可以选用神经网络模型，它可以较好的拟合这些数据，这也是神经网络模型的一个主要的优点。

接下来，为梯度下降定义一些变量和参数：

```
In [3]: num_examples = len(X) # 训练集大小
        nn_input_dim = 2 # 输入层维度
```

```
nn_output_dim = 2 # 输出层维度
```

```
# 设定梯度参数
```

```
epsilon = 0.01
```

```
reg_lambda = 0.01
```

接着我们用函数来衡量模型给出的结果是否令人满意。

并且用函数帮助我们计算神经网络的输出；最后，用这个函数来训练神经网络，它利用反向传播导数来实现批量梯度下降。

```
In [4]: def plot_decision_boundary(pred_func):
    x_min, x_max = X[:, 0].min() - .5, X[:, 0].max() + .5
    y_min, y_max = X[:, 1].min() - .5, X[:, 1].max() + .5
    h = 0.01
    xx, yy = np.meshgrid(np.arange(x_min, x_max, h), np.arange(y_min, y_max, h))
    Z = pred_func(np.c_[xx.ravel(), yy.ravel()])
    Z = Z.reshape(xx.shape)

    plt.contourf(xx, yy, Z, cmap=plt.cm.Spectral)
    plt.scatter(X[:, 0], X[:, 1], c=y, cmap=plt.cm.Spectral)
```

```
In [5]: # 计算损失函数
```

```
def calculate_loss(model):
    W1, b1, W2, b2 = model['W1'], model['b1'], model['W2'], model['b2']
    # 前向传播
    z1 = X.dot(W1) + b1
    a1 = np.tanh(z1)
    z2 = a1.dot(W2) + b2
    exp_scores = np.exp(z2)
    probs = exp_scores / np.sum(exp_scores, axis=1, keepdims=True)
    # 计算损失值
    correct_logprobs = -np.log(probs[range(num_examples), y])
    data_loss = np.sum(correct_logprobs)
    # 加限制项
    data_loss += reg_lambda/2 * (np.sum(np.square(W1)) + np.sum(np.square(W2)))
    return 1./num_examples * data_loss
```

```

def predict(model, x):
    W1, b1, W2, b2 = model['W1'], model['b1'], model['W2'], model['b2']
    # Forward propagation
    z1 = x.dot(W1) + b1
    a1 = np.tanh(z1)
    z2 = a1.dot(W2) + b2
    exp_scores = np.exp(z2)
    probs = exp_scores / np.sum(exp_scores, axis=1, keepdims=True)
    return np.argmax(probs, axis=1)

def build_model(nn_hdim, num_passes=20000, print_loss=False):

    np.random.seed(0)
    W1 = np.random.randn(nn_input_dim, nn_hdim) / np.sqrt(nn_input_dim)
    b1 = np.zeros((1, nn_hdim))
    W2 = np.random.randn(nn_hdim, nn_output_dim) / np.sqrt(nn_hdim)
    b2 = np.zeros((1, nn_output_dim))

    model = {}

    for i in range(0, num_passes):

        # 前向传播
        z1 = X.dot(W1) + b1
        a1 = np.tanh(z1)
        z2 = a1.dot(W2) + b2
        exp_scores = np.exp(z2)
        probs = exp_scores / np.sum(exp_scores, axis=1, keepdims=True)

        # 后向传播
        delta3 = probs
        delta3[range(num_examples), y] -= 1
        dW2 = (a1.T).dot(delta3)

```

```

db2 = np.sum(delta3, axis=0, keepdims=True)
delta2 = delta3.dot(W2.T) * (1 - np.power(a1, 2))
dW1 = np.dot(X.T, delta2)
db1 = np.sum(delta2, axis=0)

dW2 += reg_lambda * W2
dW1 += reg_lambda * W1

W1 += -epsilon * dW1
b1 += -epsilon * db1
W2 += -epsilon * dW2
b2 += -epsilon * db2

model = { 'W1': W1, 'b1': b1, 'W2': W2, 'b2': b2}

if print_loss and i % 1000 == 0:
    print("Loss after iteration %i: %f" %(i, calculate_loss(model)))

return model

```

In [6]: # 建立 3 个隐藏层的模型

```

model = build_model(3, print_loss=True)

# 画出决策边界
plot_decision_boundary(lambda x: predict(model, x))
plt.title("Decision Boundary for hidden layer size 3")

```


```

Loss after iteration 0: 0.360605
Loss after iteration 1000: 0.072923
Loss after iteration 2000: 0.072151
Loss after iteration 3000: 0.071875
Loss after iteration 4000: 0.071735

```

```
Loss after iteration 5000: 0.071653
Loss after iteration 6000: 0.071600
Loss after iteration 7000: 0.071565
Loss after iteration 8000: 0.071541
Loss after iteration 9000: 0.071524
Loss after iteration 10000: 0.071512
Loss after iteration 11000: 0.071503
Loss after iteration 12000: 0.071496
Loss after iteration 13000: 0.071490
Loss after iteration 14000: 0.071486
Loss after iteration 15000: 0.071483
Loss after iteration 16000: 0.071480
Loss after iteration 17000: 0.071478
Loss after iteration 18000: 0.071476
Loss after iteration 19000: 0.071474
```


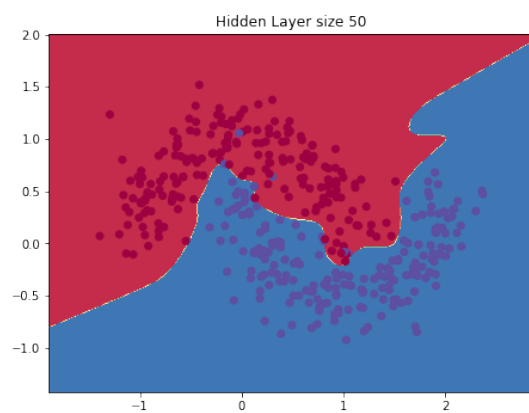


```
Out[6]: Text(0.5, 1.0, 'Decision Boundary for hidden layer size 3')
```



在上面的例子中，我们选择了有三个节点的隐藏层，现在我们改变隐藏层的大小，看看会如何影响最终的结果。

```
In [7]: plt.figure(figsize=(16, 32))
        hidden_layer_dimensions = [1, 2, 3, 4, 5, 20, 50, 100]
        for i, nn_hdim in enumerate(hidden_layer_dimensions):
            plt.subplot(5, 2, i+1)
            plt.title('Hidden Layer size %d' % nn_hdim)
            model = build_model(nn_hdim)
            plot_decision_boundary(lambda x: predict(model, x))
        plt.show()
```





从图中可以发现，适当低维度的隐藏层可以很好地捕获数据的大致边界，而过高维度的隐藏层则更易出现过度拟合。虽然过度拟合可以通过高强度的正则化进行抵销，不过选择最为合适的隐藏层就会更加“经济”的解决问题。

## 参考文献

- [1] [神经网络的理解与实现](#)
- [2] [神经网络—最易懂最清晰的一篇文章](#)
- [3] [用 Python 从头开始实现一个神经网络](#)
- [4] Neural Network, maojiaming